

FIGURA X1 — NO PRODUCIBLE

Descomposición prefill/decode por turno

Qué habría mostrado

Reparto del tiempo de cada turno entre prefill y decodificación.

Por qué no se puede producir

El nivel de LLAMADA está vacío: la API pública del camino B no expone eval_count, eval_duration, load_duration ni done_reason.

Qué haría falta

Instrumentar el backend para propagar los crudos de Ollama, o correlacionar por timestamp con los logs del servidor.