

FIGURA X3 — NO PRODUCIBLE

ttft_per_1k_in por posición de turno

Qué habría mostrado

Si el KV cache de prefijo se reutiliza entre turnos.

Por qué no se puede producir

Sin streaming y sin prompt_eval_duration por turno, la métrica no es calculable por el camino B.

Qué haría falta

Los crudos de Ollama por llamada; es la misma carencia que X1.