

Reconstrucción del protocolo del 7-ago: semáforo de las quince preguntas

	1. ¿Qué modelo? ¿digest? ¿cuantización?	NO CONSTA
	2. ¿Versión de Ollama? ¿driver? ¿GPU exacta?	NO CONSTA
	3. `num_ctx` / `num_predict` / `num_gpu`	PARCIAL
	4. `temperature`, `top_k`, `top_p`, `repeat_penalty`, `	PARCIAL
	5. ¿`format`/JSON schema? ¿cuál byte a byte?	NO CONSTA
	6. ¿Prompts exactos renderizados?	NO CONSTA
	7. ¿Warm-up? ¿corridas descartadas?	NO CONSTA
	8. ¿Concurrencia? `OLLAMA_NUM_PARALLEL`	NO CONSTA
	9. ¿Métrica de latencia?	CONSTA
	10. ¿Incluía `load_duration`? ¿cold starts?	NO CONSTA
	11. Definición de «fallo», «útil», «calla», «muere»	PARCIAL
	12. ¿Los 17 ids de fallo?	CONSTA
	13. ¿Jerarquía sesión/turno/llamada?	PARCIAL
	14. ¿Timeouts configurados?	NO CONSTA
	15. ¿Zona/región de las VMs, RTT?	NO CONSTA